

QUANT FINANCE TERMINAL ·
v2.046

SYS://CURRICULUM/D013.MD · PHASE 1 ●
LIVE

LECTURE · 量化金融 365

DAY 013 / 365

P1 · 量化基础

DEEP DIVE · 8 页深度版

假设检验入门

// Hypothesis Testing

KEY CONCEPTS · 三大要点

- ▶ 零假设
- ▶ p 值
- ▶ t 检验

01 · WHY THIS LESSON · 这节课为什么重要

本节定调

// 看完这一段你会知道:这节课跟你接下来 3 个月的学习节奏关系有多大

你回测一个策略,过去三年年化 25%,跑赢沪深三百 8 个点——这是真本事还是运气?假设检验是量化里的'测谎仪',它给你一个具体数字 p 值,告诉你这个超额收益有多大概率纯属偶然。本节讲清三件事:① 零假设 H_0 和备择假设 H_1 的对立结构(假设它没用,看数据能不能推翻这个假设);② t 检验如何从样本均值/标准差/样本量算出 t 统计量,再查表得 p 值;③ $p < 0.05$ 不是金科玉律,样本量、多次检验、 p -hacking 会让 0.05 失效。我们用真实策略回测做 t 检验,跑 1000 次随机策略仿真演示 p -hacking,看为什么学术圈现在主张 $p < 0.005$ 。学完你能用一个数字判断别人(或你自己)的策略是真本事还是赌运气。

学习目标 · LEARNING OBJECTIVES

// 听课前默念一遍,听完之后回头打勾

01 理解'零假设 H_0 '和'备择假设 H_1 '的对立结构,以及为什么先假设'没用'再去推翻

02 掌握 t 检验的三个输入(样本均值 / 样本标准差 / 样本量)和输出(t 统计量 + p 值)

03 会用 `scipy.stats.ttest_1samp` 一行做策略 t 检验,看 p 值判断显著性

04 知道 $p < 0.05$ 不是金科玉律 — 样本量大时几乎什么都显著,小时几乎什么都不显著

05 理解多次检验陷阱(同时跑 100 个策略,5 个假阳性是必然的),以及 Bonferroni 修正

06 认识 p-hacking 的真实危害,以及学术界 2017 年后主张降到 $p < 0.005$ 的原因

02 · CONTEXT · 历史与背景

Fisher、女士品茶 和 Renaissance 私房 30 年的统计纪律

// 不读历史的策略走不远

1925 年英国统计学家 Ronald Fisher 在剑桥大学一个茶会上,听一位女士说她能仅凭口感判断'奶茶'是先倒奶还是先倒茶。Fisher 不信,但他设计了一个严谨的实验:8 杯茶,4 杯先奶 4 杯先茶,随机打乱顺序让她猜。如果她全猜对了,纯靠运气的概率是 $1/70 \approx 1.4\%$ ——Fisher 设的'显著性阈值'是 5%,所以如果全对就承认她有此能力。结果她真的全对。Fisher 写进了 1935 年的《实验设计》一书,这就是**假设检验**的起源,也是 $p < 0.05$ 这个数字第一次被人为定下来的地方。

Renaissance Technologies(文艺复兴科技) 是有史以来表现最好的对冲基金,Medallion 基金 1988-2018 年扣费前年化 66%。James Simons 团队的核心纪律就一条:**任何一个新策略上线之前,必须经过严格的统计显著性检验,t 统计量必须超过 5(对应 $p < 0.0000005$,比学术界标准严 100 万倍)**。这种近乎偏执的纪律让他们 30 年没有过任何一次年度亏损。

LTCM 的反面案例(Day 8 / Day 11 反复提)。LTCM 团队也做假设检验,但他们的样本是过去 5 年(平静期),没考虑'极端时段'这种本就罕见的事件。p 值算出来都很显著,实际上是把'平静期的稳定'当成了普遍真理——1998 俄罗斯违约一个事件,把整个统计基础掀翻。**统计显著不等于现实健壮,这是金融统计最贵的一课。**

散户的真实场景:你看到雪球大 V 晒'近三年策略胜率 65%',你心动了。但他从来没告诉你:他可能同时跑了 50 个策略,只把胜率最高的拿出来晒(典型 p-hacking)。如果你做 50 次随机策略,按 5% 显著性算,会有 2-3 个'看起来很厉害'纯粹是运气。

本节最重要的两句话:**先假设它没用,看数据能不能推翻;统计显著 $\neq$ 经济意义 $\neq$ 未来稳定。**

- ▶ Ronald Fisher(1925,假设检验之父, $p < 0.05$ 起源)
- ▶ Jerzy Neyman & Egon Pearson(1933,Type I/II 错误概念,完善检验框架)
- ▶ James Simons / Renaissance($t > 5$ 严格门槛,30 年无年度亏损)
- ▶ Andrew Gelman(统计学家,2017 年带头主张降到 $p < 0.005$)
- ▶ John Ioannidis(2005 写《Why Most Published Research Findings Are False》)

03 · CORE CONCEPTS · 核心概念详解

把这几个概念彻底搞懂

// 听完视频后,确保你能给一个完全不懂的朋友讲清楚每一条

CONCEPT_01

零假设 vs 备择假设: '先假设没用,看数据能不能推翻'

假设检验的核心结构:你不是直接证明'策略有效',而是先假设'策略没用'(零假设 H_0),然后看数据有多大概率支持这种'没用'。如果概率很低(比如 $< 5\%$),就**拒绝 H_0** ,接受备择假设 H_1 。

为什么这么绕?因为'证明 X 真'比'证明 X 假'难得多。

类比:你想证明'天鹅都是白的',要看遍世界所有天鹅;但只要你看到一只黑天鹅,就能直接否定'天鹅都是白的'。

假设检验本质上是在找'反例'——找数据有多支持反例。

应用到策略:

H_0 (零假设):策略平均收益 = 0(等价于'纯靠运气')

H_1 (备择假设):策略平均收益 > 0 (等价于'真有 alpha')

我们的工作看数据是否能拒绝 H_0 。如果拒绝不了,**不能说'策略没用'**,只能说'数据不足以证明策略有用'。

经典误读:' $p > 0.05 \rightarrow$ 策略没用'。错。 $p > 0.05$ 只是说'目前数据不足以证明它有用',可能是真没用,也可能是有用但样本太小看不出来。

$H_0: \mu = 0$ vs $H_1: \mu > 0$ (单尾) 或 $H_1: \mu \neq 0$ (双尾)

▶ **举例:** 你的网格策略过去 252 天日均收益 +0.03%。 H_0 说真实日均 = 0, H_1 说真实日均 > 0 。如果数据让 H_0 看起来很离谱(p 很小),你就敢上线;如果 H_0 看起来仍可信(p 很大),你就不敢。

CONCEPT_02

p 值: '纯靠运气至少出现这么好结果的概率'

p 值定义:假设 H_0 是真的(也就是策略真的没用),那么纯靠运气至少出现这么好结果的概率有多大。

03 · CORE CONCEPTS · 续 (2/3)

CONCEPT_03

t 检验:三个输入算出一个 t 统计量

t 检验是最常用的假设检验,适用于'判断样本均值是否显著不同于零'。

公式: $t = (\bar{x} - \mu_0) / (s / \sqrt{n})$, 其中 $\bar{x}$ 是样本均值, μ_0 是 H_0 假设的真值(通常是 0), s 是样本标准差, n 是样本量。

直觉: t 统计量本质是'信号 / 噪声'。

分子 $(\bar{x} - \mu_0)$ = 信号(样本均值偏离零有多远)

分母 $(s / \sqrt{n})$ = 噪声 / $\sqrt{n}$, 样本量越大噪声越小

所以 $|t|$ 越大 → 信号越强 / 噪声越小 → 越显著。

算出 t 后查 p 值:

$t > 1.96 \rightarrow p < 0.05$ (显著)

$t > 2.58 \rightarrow p < 0.01$

$t > 3.29 \rightarrow p < 0.001$

$t > 5.00 \rightarrow p < 5 \times 10^{-7}$ (Renaissance 标准)

Python 一行: `scipy.stats.ttest_1samp(returns, popmean=0)` 返回 (t, p)。简单到没朋友。

$$t = (\bar{x} - \mu_0) / (s / \sqrt{n}) \quad \text{自由度 } df = n - 1$$

► **举例:** 策略 252 天日收益, 样本均值 0.03%, 样本标准差 1.0%, $n=252$ 。 $t = 0.0003 / (0.01/\sqrt{252}) = 0.0003 / 0.00063 \approx 0.48$ 。 t 太小, $p \approx 0.32$, 不显著。想让 t 大, 要么提高均值(增 alpha), 要么降低 std(降波动), 要么增加样本(更长回测)。

CONCEPT_04

Type I / Type II 错误 + 检验功效(power)

假设检验的两种错误:

Type I 错误(假阳性, α): H_0 实际为真, 但你错误拒绝它(误以为策略有用, 其实没用)

Type II 错误(假阴性, β): H_1 实际为真, 但你错误保留 H_0 (放过一个真有用的策略)

$p < 0.05$ 控制的是 α 水平(假阳性率)。但很多人忘了 β 也很重要——如果你的策略真的有 alpha 但样本太少没检测出来, 你白白错过它。

03 · CORE CONCEPTS · 续 (3/3)

CONCEPT_05

多次检验 + p-hacking + Bonferroni 修正

多次检验陷阱:你同时测 100 个策略,按 $\alpha=0.05$,纯运气会有大约 5 个假阳性。这是数学必然 — $100 \times 0.05 = 5$ 。

p-hacking 是金融研究最大的瘟疫:

- ① 跑 1000 个不同参数的策略,只把 p 最小的报告
- ② 不停换样本期(2018-2020 不显著?换 2019-2021)直到出来一个 < 0.05
- ③ 加入特征 / 删除特征 / 调超参,直到结果好看

效果:看起来'统计显著'的论文 / 策略,实际可能只是大量尝试中的运气幸存者。Ioannidis 2005 那篇著名论文标题就叫《Why Most Published Research Findings Are False》。

Bonferroni 修正:同时做 m 个检验,把 α 阈值从 0.05 降到 $0.05/m$ 。

测 100 个策略 → 阈值 0.0005。这非常保守,不是最优修正(还有 FDR、Holm 等),但简单粗暴有效。

学术界 2017 后主张 $p < 0.005$ (Benjamin et al., 2018 论文 'Redefine Statistical Significance')。理由:0.05 太松了,大量'显著结果'重现不了(replication crisis)。Renaissance 要 $t > 5$ 远比这严。

散户实战:① 在固定回测期(out-of-sample)只跑一次,不要换日期换参数

- ② 多个策略用 Bonferroni 或更现代方法(FDR)
- ③ 实盘前必须有 forward test(walk-forward)6 个月以上
- ④ p-value 不是唯一证据,要看经济直觉

Bonferroni 修正: $\alpha_{\text{corrected}} = \alpha / m$, $m = \text{检验次数}$

► **举例:** 你跑 50 个不同因子做选股,每个都做 t 检验。按 $\alpha=0.05$ 你会期待 2-3 个假阳性。Bonferroni 修正后阈值 = $0.05/50 = 0.001$,只有 $t > 3.3$ 的因子才能进入下一轮。

04 · PYTHON LAB · 真实可跑代码

策略 t 检验 + 多次检验仿真 + 真实回测显著性

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

► **实操原则:** 先跑通(哪怕硬编码),再优化(参数化/函数化),最后才追求精度(模型升级/特征工程)。散户量化最大的坑是没跑通就开始优化。

```
# day_013_hypothesis.py - 假设检验在量化策略中的实战
import numpy as np, pandas as pd, yfinance as yf
import scipy.stats as stats
import matplotlib.pyplot as plt

# ===== 1. 真实策略 t 检验: 沪深三百均线策略 =====
px = yf.download('510300.SS', period='3y', auto_adjust=True)['Close'].squeeze()
ret = px.pct_change().dropna()

# 简单均线策略: 20 日均线上买入持有, 下穿空仓
ma20 = px.rolling(20).mean()
signal = (px > ma20).shift(1).fillna(False).astype(int)
strat_ret = (signal * ret).dropna()

# t 检验:  $H_0 = \text{策略日均收益} = 0$ 
t_stat, p_val = stats.ttest_1samp(strat_ret, popmean=0)
n = len(strat_ret)
annualized = strat_ret.mean() * 252
sharpe = strat_ret.mean() / strat_ret.std() * np.sqrt(252)

result = pd.DataFrame({
    '指标': ['样本量(天)', '日均收益(%)', '年化(%)', 'Sharpe', 't 统计量', 'p 值'],
    '数值': [n, strat_ret.mean()*100, annualized*100, sharpe, t_stat, p_val],
})
```

04 · PYTHON LAB · 真实可跑代码 · 续 (2/3)

策略 t 检验 + 多次检验仿真 + 真实回测显著性

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

```
print('=== 沪深三百 20 日均线策略 t 检验 ===')
print(result.to_string(index=False))
verdict = '显著' if p_val < 0.05 else '不显著(可能纯运气)'
print(f'\n判断:{verdict}(α=0.05)')

# ===== 2. 多次检验仿真:1000 个随机策略,看几个'假阳性' =====
np.random.seed(42)
n_strategies, n_days = 1000, 252
p_values = []
for _ in range(n_strategies):
    fake_ret = np.random.normal(0, 0.01, n_days) # 真实 mean=0
    _, p = stats.ttest_1samp(fake_ret, 0)
    p_values.append(p)
p_values = np.array(p_values)

false_positives = (p_values < 0.05).sum()
bonferroni = (p_values < 0.05/n_strategies).sum()
print(f'\n=== 1000 个随机策略多次检验 ===')
print(f'按 α=0.05 假阳性数 = {false_positives}(理论 50)')
print(f'Bonferroni 修正(α=0.00005)假阳性数 = {bonferroni}')

# ===== 3. p-hacking 演示:换 50 个回测期 =====
print(f'\n=== p-hacking 演示:同一策略,换不同回测窗口 ===')
windows = [(strat_ret.iloc[i:i+150]) for i in range(0, len(strat_ret)-150, 10)]
p_per_window = [float(stats.ttest_1samp(w, 0).pvalue) for w in windows if
len(w)==150]
min_p_w = min(p_per_window)
print(f'最小 p 值 = {min_p_w:.4f} (在 {len(p_per_window)} 个窗口中)')
print(f'按 α=0.05 数 = {sum(p<0.05 for p in p_per_window)}/{len(p_per_window)}')
print(f'△ 只报告最小 p 值就是 p-hacking,真实显著性远低于这个数字')
```

04 · PYTHON LAB · 真实可跑代码 · 续 (3/3)

策略 t 检验 + 多次检验仿真 + 真实回测显著性

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

```
# ===== 4. 可视化:p 值分布 =====
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
axes[0].hist(p_values, bins=50, color='steelblue', edgecolor='black')
axes[0].axvline(0.05, color='red', linestyle='--', linewidth=2, label='α=0.05')
axes[0].set_title(f'1000 个随机策略 p 值分布 · 假阳性 {false_positives} 个')
axes[0].set_xlabel('p 值'); axes[0].set_ylabel('频数'); axes[0].legend()


axes[1].plot(strat_ret.cumsum().values, color='steelblue')
axes[1].set_title(f'沪深三百均线策略累计收益(t={t_stat:.2f}, p={p_val:.4f})')
axes[1].set_xlabel('交易日'); axes[1].set_ylabel('累计对数收益')
axes[1].grid(True, alpha=0.3)

plt.tight_layout()
plt.savefig('day013_hypothesis.png', dpi=120)
print('\n✓ 图已保存到 day013_hypothesis.png')
```

05 · CHART + ANALYSIS · 看图说话

假设检验的真实威力 · p 值分布 + 策略累计曲线

// 1000 个随机策略 p 值分布(左) + 真实策略 t 检验结果(右) · matplotlib 真实输出



1000 随机策略

~50 个
 $p < 0.05$

假阳性是数学必然 · $\alpha = 0.05 \rightarrow$
5% 概率

Bonferroni 修正

0 个假阳性

$\alpha = 5 \times 10^{-5}$ · 但太严会让真信号
也漏

Renaissance 标准

$t > 5 (p < 5 \times 10^{-7})$

200 万分之一 · 30 年无亏损

ANALYSIS · 这张图告诉我们什么

► 01 随机策略 p 值是均匀分布

p 值在 $[0, 1]$ 上均匀分布是 H_0 真时的数学性质。1000 个里约 50 个落在 < 0.05 , 完全可预期。如果你跑 100 个策略只挑 p 最小的报告, 你就是把这 50 个'幸运者'当作'真信号'。

► 02 Bonferroni 太严 vs FDR 折中

Bonferroni 把假阳性几乎全压到 0, 代价是真阳性也被埋。学术界更常用 BH-FDR(False Discovery Rate)控制方法, 允许少量假阳性换取更高检测能力。Python 用 `statsmodels.stats.multitest.fdr_correction`。

► 03 策略时间序列要看 Sharpe + p 值 + Power

光看年化收益、Sharpe、回撤都不够。一个 Sharpe 1.5 的策略, 如果样本只有 6 个月, p 值可能 > 0.1 , 你不能确定它是真本事。完整评估必须三件: Sharpe + p 值 + power(样本量是否够)。

A 股 · 港股 · 美股 · 加密 全覆盖

// 每个案例都有具体标的和数字,方便你立刻验证

Renaissance Medallion(30 年无年度亏 损)	私募基金内部纪律	James Simons 团队所有新策略上线必须 $t > 5(p < 5 \times 10^{-7})$ 。比学术 0.05 严 100 万倍。30 年扣费前年化 66%,从未年度亏损,靠的就是这个近乎偏执的统计纪律 + 大样本 + 跨策略组合。
学术界 Replication Crisis	心理学 / 医学 / 经 济学	2015 年 Reproducibility Project 重做 100 篇心理学顶刊论文,只有 36 篇能复现原结果。p-hacking + 多次检验 + 出版偏差是元凶。金融论文也好不到哪去,Harvey/Liu 2014 估计学术金融文献假阳性率 30%+。
LTCM 1998 (反 面案例)	Long-Term Capital Management	诺奖团队的策略每个 $t > 3$ (高显著)。但样本只有 4-5 年平静期,没考虑'极端时段'。统计上显著 + 现实中脆弱 = 几个月亏 90%。统计显著 $\neq$ 经济稳健。
雪球大 V 晒 单	散户实战陷阱	大 V 说'近一年策略胜率 65%',你心动。但他没说同时跑了 50 个变体,只把胜率最高的拿出来 — 典型 p-hacking。对照:50 个随机策略按 $\alpha=0.05$ 期望 2-3 个'看起来很厉害',就是这种。
Sharpe 比 率 + t 统 计量的关系	回测显著性快速估算	对日数据, $t = \text{Sharpe} \times \sqrt{n} / \sqrt{252}$ 。意思是:Sharpe=1.0 + 252 天 $\rightarrow t \approx 1.0$ (不显著);Sharpe=1.0 + 1000 天 $\rightarrow t \approx 2.0$ (边缘);Sharpe=1.5 + 1000 天 $\rightarrow t \approx 3.0$ (显著)。所以 Sharpe < 1 + 短回测期 = 不要相信任何单一回测结果。

这些坑你不主动避 · 迟早会主动找上你

// 每个坑都附了避坑动作,而不是只描述现象

△ 01

把 $p > 0.05$ 当成'策略没用'

$p > 0.05$ 只意味着'数据不足以拒绝 H_0 ',可能真没用,也可能有用但样本太小。正确做法:看 power(检验功效),如果 power 才 0.3,你只是没看到信号,不是没信号。策略的 Sharpe 可能合理,但需要更长样本来确认。

△ 02

p-hacking — 跑 100 个策略只报最好的

1000 个随机策略按 $\alpha=0.05$,期望 50 个假阳性。如果你只挑 p 最小的报告,你的报告就是这 50 个幸运者之一。雪球大 V / 量化论文 / 私募市场介绍材料里大量存在这种。做研究必须固定计划 + 预先注册检验方案 + 用 Bonferroni 或 FDR 修正。

△ 03

样本量决定一切 — 别拿 1 个月数据下结论

$n=20$ 的样本算 t 检验完全不可信,因为分母 $\sqrt{n}$ 让噪声极大。金融策略最少 1 年 (252 天),稳健需要 3-5 年(750-1250 天)。Renaissance 用 30 年数据 + 跨策略 + 大样本,所以才敢做出 $t > 5$ 的判断。

△ 04

统计显著 $\neq$ 经济意义

样本量足够大时,即使 0.001% 的微小 α 也能显著($t > 5$)。但 0.001%/天年化 0.25%,扣掉手续费 / 滑点 / 税后实际为负。实战要看 effect size(收益绝对值)+ 显著性,两者都重要。 p 值告诉你'是不是运气',收益数字告诉你'值不值得做'。

△ 05

正态假设失效时 t 检验也失效

t 检验假设残差近似正态。但金融数据 Day 10/11 讲过——尾巴极厚。极端日会让 t 统计量被几次大涨/大跌主导, p 值不可信。替代方案:① bootstrap 重抽样(无分布假设)② 学生 t 分布 + robust SE ③ 永远画 Q-Q 图先看分布。

06 · STANDARD OPERATING PROCEDURE · 实战规则

假设检验实战 SOP

// 按这套规则走,你的执行力会立刻拉到中等机构水平

- 01 策略上线前必做 t 检验 + 看 p 值,Sharpe 单独不够
- 02 $\alpha=0.05$ 是底线,严肃量化用 0.01 或更严(Renaissance $t>5$)
- 03 样本量最少 252 天(1 年),稳健 3-5 年,小于 6 个月不做结论
- 04 多策略同时测必须 Bonferroni 或 FDR 修正
- 05 做研究先写检验方案,不要数据看完再决定方向(避免 p-hacking)
- 06 p 值 + effect size 都要看,统计显著 $\neq$ 经济显著
- 07 正态假设可疑时用 bootstrap 或 robust SE 替代 t 检验

► **纪律 > 灵感:** 量化做久的人都明白,赚钱的不是某一次绝妙判断,而是把规则坚持执行 1000 次。打印这一页,贴在你电脑边。

07 · RECAP · 一页课件总结

把这节课带走的几件事

// 打印或截图这一页, 3 天后再看一遍效果最好

- 01 假设检验结构:先假设'没用'(H₀),看数据能否推翻它,推翻就接受备择假设(H₁)。
- 02 p 值是'纯运气至少出现这么好结果的概率',不是 H₀ 为真的概率。
- 03 t 检验: $t = (\bar{x} - \mu_0) / (s / \sqrt{n})$,信号 / 噪声, $|t|$ 大 $\rightarrow$ p 小 $\rightarrow$ 显著。
- 04 $\alpha=0.05$ 是 1925 年 Fisher 拍脑袋定的;Renaissance 用 $t>5$ ($p<5\times 10^{-7}$) 严 100 万倍。
- 05 Type I 错误(假阳性 α)常被关注,Type II(假阴性 β)和 power($1-\beta$)也很重要。
- 06 多次检验陷阱:跑 100 个策略期望 5 个假阳性。必须 Bonferroni 或 FDR 修正。
- 07 p-hacking 三种典型:多策略只报最好 / 换样本期 / 调参直到显著。学术界 30% 论文有此嫌疑。
- 08 统计显著 $\neq$ 经济显著 $\neq$ 未来稳健 — LTCM 输光就是因为忘了第三件。

08 · SELF-CHECK · 自测题

答不上来的回看视频对应段落

// 这几道题都没标准答案,目的是逼你自己组织语言讲清楚

Q01 你回测一个策略 252 天,Sharpe=0.8,t 统计量大约多少?p 值大约多少?显著吗?

Q02 解释:为什么 Renaissance 用 $t > 5$ 而不是学术界的 $t > 1.96$?这两个数对应的概率分别是多少?

Q03 你看到一篇量化论文报告 $p=0.03$,他们测了 50 个因子,只报告这一个。Bonferroni 修正后这个 p 还显著吗?

Q04 p-hacking 的三种典型形式是什么?你自己做研究怎么防止?

Q05 举一个'统计上显著但经济上没意义'的真实例子。这告诉我们 p 值和什么必须一起看?

09 · NEXT STEP · 下一步

继续往前走

// 看完这节,下面是延伸方向 + 明天预告

推荐阅读 · FURTHER READING

// 听完今天的内容还想往深里挖的话

- ▶ Fisher 《The Design of Experiments》(1935)– 假设检验经典, $p < 0.05$ 的源头
- ▶ Ioannidis 《Why Most Published Research Findings Are False》(PLoS Medicine, 2005)
– 统计学最被引用论文
- ▶ Benjamin et al. 《Redefine Statistical Significance》(Nature Human Behaviour, 2018)– 主张 α 降到 0.005
- ▶ Harvey/Liu/Zhu 《...and the Cross-Section of Expected Returns》(2016)– 金融因子假阳性率分析
- ▶ `scipy.stats` 文档 + `statsmodels.stats.multitest` – Python 量化标配

NEXT LECTURE · 下一节预告

DAY 014 R^2 与策略评估

Day 14: R^2 与策略评估 — Day 9 讲过 R^2 是回归方程的解释力,这一节专门讲 R^2 在策略评估里的应用 / 局限 / 陷阱,以及 Adjusted R^2 、out-of-sample R^2 这两个更可靠的版本。