

QUANT FINANCE TERMINAL ·
v2.046

SYS://CURRICULUM/D014.MD · PHASE 1 ●
LIVE

LECTURE · 量化金融 365

DAY 014 / 365

P1 · 量化基础

DEEP DIVE · 8 页深度版

R² 与策略评估

// R-squared in Strategies

KEY CONCEPTS · 三大要点

- ▶ 拟合度
- ▶ 样本外 R²
- ▶ 解释 vs 预测

01 · WHY THIS LESSON · 这节课为什么重要

本节定调

// 看完这一段你会知道:这节课跟你接下来 3 个月的学习节奏关系有多大

R^2 是评价模型解释力的量化指标。如果说 Day 9 的贝塔告诉你'股票跟大盘走的方向有多陡', R^2 告诉你'这条棍子贴得多紧'。两个值合起来才是完整画像。本节讲清五件事:① R^2 的几何直觉(在散点图里它就是棍子贴近度);② 公式 $1 - SS_{res}/SS_{tot}$ 怎么算 + 物理含义;③ 高 R^2 不一定是好事——主动基金 R^2 大于零点九五就是 closet indexing 抱指数躺平;④ Adjusted R^2 防止你靠加垃圾变量提分;⑤ in-sample R^2 vs out-of-sample R^2 是评估过拟合最直接的工具,落差大于一半视为警告。学完你能用三个数字(贝塔 + R^2 + 调整 R^2)给任何一只股票或任何一个策略打出体检报告,看出它是真的 alpha 还是假的独立、是真本事还是抱指数。

学习目标 · LEARNING OBJECTIVES

// 听课前默念一遍,听完之后回头打勾

01 理解 R^2 的几何直觉 — 棍子贴散点的紧密度,以及 R^2 在零到一区间的物理含义

02 掌握 $R^2 = 1 - SS_{\text{res}}/SS_{\text{tot}}$ 的计算和'解释方差占比'的核心解读

03 区分'高贝塔 + 高 R^2 '(跟随风格)、'高贝塔 + 低 R^2 '(独立)、'低贝塔 + 低 R^2 '(防御)三种股票画像

04 知道为什么 Adjusted R^2 比普通 R^2 更可靠 — 加垃圾变量也能把 R^2 推上去

05 掌握 in-sample R^2 vs out-of-sample R^2 双值报告纪律 — 出样本 R^2 跌幅大于一半视为过拟合警告

06 识别'主动基金 R^2 大于零点九五'是 closet indexing 抱指数,不是真 alpha

02 · CONTEXT · 历史与背景

Cremers 与 Petajisto 二零零九揭穿 closet indexing — 一篇论文让三成主动基金现形

// 不读历史的策略走不远

二零零九年耶鲁大学的 Martijn Cremers 和 Antti Petajisto 发表了一篇震动整个共同基金界的论文 — 《How Active Is Your Fund Manager? A New Measure That Predicts Performance》。他们提出了一个简单到令人尴尬的指标:Active Share — 看一只主动基金的持仓和它对标指数有多大重叠。 R^2 跟这个故事密切相关:如果你把主动基金的日收益对沪深三百或者标普五百做线性回归, R^2 越高说明它越像指数。

他们查了一九八零到二零零三年所有美国主动股票基金,发现三成以上的所谓'主动'基金 R^2 大于零点九五(意思是收益的百分之九十五能用指数解释),Active Share 只有百分之二十到四十(意思是它实际买的就是指数成分股)。这些基金收着百分之一点五的主动管理费,实际只是抱住指数躺平 — 学术界把这叫 closet indexing,衣柜里的指数基金。投资者付主动费用却拿被动产品。论文一发,SEC 开始监管,欧洲也开始调查,数千只基金被迫调整持仓或者降费。

中国基金界二零二零到二零二一年也发生过完全一样的事 — 千亿级'主动'基金清一色重仓茅台、五粮液、海天味业、宁德时代、隆基绿能这一篮子茅指数和宁组合,跟沪深三百和创业板指数的 R^2 在零点八五以上。那两年看似主动管理,实际是高费率版的指数 ETF。二零二二年指数回调三成五,这些基金净值同步腰斩,投资者才意识到费用全白付。

R^2 这个看起来很学术的指标,在现实里是揭穿伪装的探照灯。**散户买基金第一件事:看它跟指数 R^2 是多少。**大于零点九五立刻换 ETF,中间段才考虑费率是否值得。

- ▶ Martijn Cremers 与 Antti Petajisto(二零零九 Active Share 论文 + R^2 揭穿 closet indexing)
- ▶ Karl Pearson(一九零三年提出相关系数的平方就是 R^2 雏形)
- ▶ Eugene Fama 与 Kenneth French(三因子模型对个股 R^2 平均零点七到零点九)
- ▶ Andrew Lo(MIT Sloan,大量 R^2 与 alpha 关系研究)

把这几个概念彻底搞懂

// 听完视频后,确保你能给一个完全不懂的朋友讲清楚每一条

CONCEPT_01

R² 的几何直觉:棍子贴散点贴得有多紧

Day 9 我们讲了贝塔 — 用最小二乘法拟合一条棍子,棍子的斜率就是贝塔。今天讲第二个量:这条棍子贴得有多紧。

直觉:在散点图里画一条最佳拟合线,然后量每个点离这条线的垂直距离(叫残差)。所有残差越小,意味着棍子贴得越紧,R² 越高。

- R² 等于一:所有点都在棍子上,完美预测。现实中几乎不可能,数据完全无噪声才行。
- R² 等于零:棍子还不如样本均值有用。模型没解释任何东西。
- R² 等于零点八五:模型解释了百分之八十五的波动,百分之十五是无法解释的'噪声'(叫 idiosyncratic 个股特性,或黑天鹅,或测量误差)

金融场景:沪深三百 ETF 对沪深三百指数 R² 接近一(几乎完美);平安银行对沪深三百 R² 大约零点六(银行整体跟金融板块走);紫金矿业对沪深三百 R² 大约零点三(它跟铜价、黄金价更相关);长江电力对沪深三百 R² 大约零点二(防御股,自己一个节奏)。

$R^2 \in [0, 1]$ 越接近 1 → 棍子贴得越紧 → 模型解释力越强

► **举例:** 你给沪深三百成分股(三百只)分别对沪深三百指数做回归,R² 中位数大约零点六。意思是平均一只股票百分之六十的波动能用大盘解释,百分之四十是它自己的故事。这就是为什么单一 ETF 风险还不够分散 — 跟大盘相关的部分可以一起跌。

CONCEPT_02

公式背后的直觉:R² = 1 - 残差方差 / 总方差

R² 公式三步走:

- **第一步:总方差 SS_tot:=** 把所有 y 减去 y 的均值,平方后加总。意思是'数据本身的总散开程度'。
- **第二步:残差方差 SS_res:=** 把所有 实际 y 减去 预测 y 的差,平方后加总。意思是'模型预测后还剩多少波动没解释'。
- **第三步:R² = 1 - SS_res / SS_tot**

03 · CORE CONCEPTS · 续 (2/3)

CONCEPT_03

Adjusted R²:多变量回归的诚实者

普通 R² 有个致命缺陷:你每加一个变量,R² 必涨(数学性质)。哪怕你加的是完全随机的噪声,R² 也会涨,虽然涨得很少。这就给'靠加变量造假'开了门。

- **Adjusted R²**:(中文叫调整后 R²)加了惩罚项:多一个变量,Adj R² 不一定涨,如果新变量没真正贡献,Adj R² 反而会降。
- **公式**:Adj R² = 1 减去 (1-R²) 乘以 (n-1) 除以 (n-k-1),其中 n 是样本量,k 是自变量个数。
- **实战意义**:任何多因子模型必报 Adj R²。
- 三因子 Fama-French (k=3),普通 R² 对个股大约零点七五,Adj R² 大约零点七四五(几乎一致)
- 五因子 (k=5)、十因子 (k=10),如果新加的不是真因子,Adj R² 会先涨后跌甚至直接下降
- **散户判断**:看到任何研究材料里说'我加了二十个特征 R² 涨到零点九二' → 立即问'Adj R² 是多少'。如果对方支吾或没算,说明这是垃圾变量堆出来的 R²。

$$\text{Adj } R^2 = 1 - (1 - R^2) \times (n - 1) / (n - k - 1) \quad k = \text{自变量数}$$

► **举例**: 你做多因子选股,n 等于一千天:用一个因子 R² 等于零点一零,Adj R² 大约零点零九九。加到五个因子 R² 等于零点一八,Adj R² 大约零点一七六。再加到三十个因子 R² 等于零点二零,Adj R² 只有零点一七六 — 后二十五个因子总共贡献为零,说明它们是垃圾。

CONCEPT_04

in-sample R² vs out-of-sample R²(过拟合检测器,本节最重要)

普通 R² 都是 in-sample(中文叫样本内)— 用全部数据拟合,然后看模型对同一份数据的解释力。这个数字几乎一定好看。

Out-of-sample R²(样本外 R²) 是真正的金标准:用一段历史数据拟合模型,然后用'模型从未见过'的另一段数据测它的解释力。

计算流程(三步):

- 第一步:in-sample(前两年数据,叫训练集),拟合 → R²_in 算出来比如等于零点六五
- 第二步:out-of-sample(后一年,叫测试集),用上面拟合的模型去预测,算 R²_out
- 第三步:对比。如果 R²_out 跌到零点三零 → 已经过拟合了;如果 R²_out 接近 R²_in → 模型稳健

03 · CORE CONCEPTS · 续 (3/3)

CONCEPT_05

高 R^2 不一定是好事 — closet indexing 警钟

对个股做回归 R^2 越高越能解释,这是好事。但对**主动管理产品**做回归, R^2 越高反而是危险信号。

主动基金的 R^2 谱:

- R^2 小于零点五:深度主动管理(选股、择时、行业偏离明显),费率合理
- 零点五到零点八五:中度主动 — 大多数中国主动基金落在这里
- 零点八五到零点九五:轻度主动 — 已经接近 closet indexing
- 大于零点九五:**closet indexing(衣柜里的指数基金)** — 主动费率被动业绩,投资者亏的是费用差

为什么基金经理愿意 closet?因为偏离指数等于跟踪误差大,等于业绩有可能跑输大盘,等于失业。抱住指数加上收百分之一点五的费 = 旱涝保收。

散户检测方法:

1. 拉基金近两百五十天日收益,对沪深三百或者中证八百做线性回归
2. 看 R^2 — 如果大于零点九零警告,大于零点九五立即换 ETF
3. 看 Active Share(持仓非指数权重之和的一半)— Cremers 和 Petajisto 标准小于百分之六十就是 closet

中国二零二零到二零二一年茅指数和宁组合现象 — 多只千亿主动基金互相抱团 R^2 在零点八五以上,本质上变成了高费率茅指数 ETF。

Active Share = $0.5 \times \sum |w_{\text{fund}} - w_{\text{index}}| < 60\%$ 视为 closet indexing

► **举例:** 某千亿主动基金二零二零到二零二一年对沪深三百 R^2 等于零点九二,对茅指数 R^2 等于零点九六,Active Share 百分之三十五。结论:这不是主动基金,是高费茅指数 ETF。二零二二年茅指数下跌百分之三十五,基金净值下跌百分之三十三,管理费照收百分之一点五。

04 · PYTHON LAB · 真实可跑代码

R² 三视角:个股画像 + 加因子 Adj R² 检验 + in/out 过拟合检测

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

► **实操原则:** 先跑通(哪怕硬编码),再优化(参数化/函数化),最后才追求精度(模型升级/特征工程)。散户量化最大的坑是没跑通就开始优化。

```
# day_014_r2_strategy_eval.py - R2 在策略评估的三个真实场景
import numpy as np, pandas as pd, yfinance as yf
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score

# ===== 1. 拉 4 只标的 + 沪深300 三年数据 =====
tickers = {
    '沪深300': '510300.SS',
    '平安银行': '000001.SZ', # 高β + 高R2(跟大盘)
    '紫金矿业': '601899.SS', # 高β + 中R2(商品周期)
    '长江电力': '600900.SS', # 低β + 低R2(防御独立)
    '招商银行': '600036.SS', # 比较组
}
raw = yf.download(list(tickers.values()), period='3y', auto_adjust=True)['Close']
# yfinance 字母序返回 → 用 dict 显式按 ticker 名字映射,避免列错位
raw = pd.DataFrame({name: raw[ticker] for name, ticker in tickers.items()})
ret = raw.pct_change().dropna()
mkt = ret['沪深300']
print(f'数据样本量:{len(ret)} 个交易日')

# ===== 2. 三只股票对沪深300 单因子回归 - 算β 和 R2 =====
print('\n=== 三种股票画像 · 单因子回归 ===')
rows = []
```


04 · PYTHON LAB · 真实可跑代码 · 续 (2/5)

R² 三视角:个股画像 + 加因子 Adj R² 检验 + in/out 过拟合检测

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

```
for name in ['平安银行', '紫金矿业', '长江电力', '招商银行']:
    y = ret[name].values.reshape(-1, 1)
    X = mkt.values.reshape(-1, 1)
    model = LinearRegression().fit(X, y)
    beta = float(model.coef_[0][0])
    r2 = float(model.score(X, y))
    pic = '跟随大盘' if r2 > 0.5 else ('半独立' if r2 > 0.25 else '基本独立')
    rows.append({'股票': name, 'β': round(beta, 3), 'R²': round(r2, 3), '画像': pic})
df1 = pd.DataFrame(rows)
print(df1.to_string(index=False))

# ===== 3. Adjusted R² 演示 - 加垃圾变量怎么暴露 =====
print('\n=== Adj R² 揭穿垃圾因子 ===')
np.random.seed(42)
n = len(ret)
y_t = ret['平安银行'].values
X1 = ret[['沪深300']].values
X2 = np.column_stack([X1, np.random.normal(0, 0.01, n)])
X6 = np.column_stack([X1, np.random.normal(0, 0.01, (n, 5))])
X21 = np.column_stack([X1, np.random.normal(0, 0.01, (n, 20))])

def adj_r2(X, y):
    m = LinearRegression().fit(X, y)
    r2_v = m.score(X, y)
    n_, k = X.shape
    adj = 1 - (1 - r2_v) * (n_ - 1) / (n_ - k - 1)
    return r2_v, adj

results_adj = [adj_r2(X, y_t) for X in (X1, X2, X6, X21)]
df2 = pd.DataFrame({
```

04 · PYTHON LAB · 真实可跑代码 · 续 (3/5)

R² 三视角:个股画像 + 加因子 Adj R² 检验 + in/out 过拟合检测

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

```
'模型': ['只用大盘 (1)', '+1 噪声 (2)', '+5 噪声 (6)', '+20 噪声 (21)'],
'R²': [round(r,4) for r,_ in results_adj],
'Adj R²': [round(a,4) for _,a in results_adj],
})
print(df2.to_string(index=False))
print('R² 一直涨 / Adj R² 加垃圾后停涨甚至降 → Adj R² 是诚实者')

# ===== 4. in-sample vs out-of-sample R² 过拟合检测 =====
print('\n=== in/out R² 过拟合检测 ===')
np.random.seed(7)
X_pool = np.column_stack([mkt.values, np.random.normal(0, 0.01, (n, 24))])
split = int(n * 0.7)
X_tr, X_te = X_pool[:split], X_pool[split:]
y_tr, y_te = y_t[:split], y_t[split:]

m_clean = LinearRegression().fit(X_tr[:, :1], y_tr)
r2_in_c = m_clean.score(X_tr[:, :1], y_tr)
r2_out_c = r2_score(y_te, m_clean.predict(X_te[:, :1]))

m_over = LinearRegression().fit(X_tr, y_tr)
r2_in_o = m_over.score(X_tr, y_tr)
r2_out_o = r2_score(y_te, m_over.predict(X_te))

df3 = pd.DataFrame({
'模型': ['A · 只用大盘', 'B · 加 24 垃圾'],
'R²_in': [round(r2_in_c, 4), round(r2_in_o, 4)],
'R²_out': [round(r2_out_c, 4), round(r2_out_o, 4)],
'落差%': [
round((1 - r2_out_c / r2_in_c) * 100, 1) if r2_in_c > 0 else 0,
round((1 - r2_out_o / r2_in_o) * 100, 1) if r2_in_o > 0 else 0,
```

04 · PYTHON LAB · 真实可跑代码 · 续 (4/5)

R² 三视角:个股画像 + 加因子 Adj R² 检验 + in/out 过拟合检测

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

```
],
})
print(df3.to_string(index=False))
print('A 模型 R2_in/R2_out 接近 → 稳健; B 模型 R2_in 高 R2_out 暴跌 → 过拟合')

# ===== 5. 可视化 =====
fig, axes = plt.subplots(1, 3, figsize=(18, 5))

colors = {'平安银行': 'tab:blue', '紫金矿业': 'tab:orange', '长江电力': 'tab:green'}
for name, color in colors.items():
    axes[0].scatter(mkt.values*100, ret[name].values*100, alpha=0.3, color=color,
                    s=10, label=name)
    xline = np.linspace(mkt.min(), mkt.max(), 50)
    for name, color in colors.items():
        m = LinearRegression().fit(mkt.values.reshape(-1,1), ret[name].values)
        axes[0].plot(xline*100, m.predict(xline.reshape(-1,1))*100, color=color,
                     linewidth=2)
    axes[0].set_xlabel('沪深300 日收益 (%)'); axes[0].set_ylabel('个股日收益 (%)')
    axes[0].set_title('三种 β + R2 画像 · 棍子贴紧度肉眼可见')
    axes[0].legend(); axes[0].grid(True, alpha=0.3)
    axes[0].axhline(0, color='gray', alpha=0.5); axes[0].axvline(0, color='gray',
alpha=0.5)

n_vars = [1, 2, 6, 21]
r2_vals = [r for r, _ in results_adj]
adj_vals = [a for _, a in results_adj]
axes[1].plot(n_vars, r2_vals, 'o-', color='tab:red', linewidth=2, markersize=10,
             label='普通 R2')
axes[1].plot(n_vars, adj_vals, 's-', color='tab:blue', linewidth=2,
             markersize=10, label='Adj R2')
axes[1].set_xlabel('总变量数(只有 1 个真因子)'); axes[1].set_ylabel('R2')
axes[1].set_title('Adj R2 揭穿垃圾 · R2 一直涨 Adj R2 拒绝跟涨')
axes[1].legend(); axes[1].grid(True, alpha=0.3)

labels = ['A · 只用大盘\n(简洁)', 'B · 加 24 噪声\n(过拟合)']
```

04 · PYTHON LAB · 真实可跑代码 · 续 (5/5)

R² 三视角:个股画像 + 加因子 Adj R² 检验 + in/out 过拟合检测

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。


```
x = np.arange(2); w = 0.35
axes[2].bar(x - w/2, [r2_in_c, r2_in_o], w, label='R2_in (训练)',
color='tab:blue')
axes[2].bar(x + w/2, [r2_out_c, r2_out_o], w, label='R2_out (测试)',
color='tab:red')
axes[2].set_xticks(x); axes[2].set_xticklabels(labels)
axes[2].set_ylabel('R2')
axes[2].set_title('in vs out R2 过拟合检测 · 模型B 落差暴露问题')
axes[2].legend(); axes[2].grid(True, alpha=0.3, axis='y')
axes[2].axhline(0, color='black', linewidth=0.5)

plt.tight_layout()
plt.savefig('day014_r2_eval.png', dpi=120)
print('\n✓ 图已保存到 day014_r2_eval.png')
```

05 · CHART + ANALYSIS · 看图说话

R² 三视角 · 个股画像 + Adj R² 实测 + 样本外过拟合

// 三层股票画像 + 加垃圾变量 R² vs Adj R² + 训练/测试 R² 对比 · matplotlib 真实输出



紫金矿业 高 β 低 R^2

$\beta=0.99$ ·
 $R^2=0.24$

β 接近 1 但大盘只解释 24% ·
商品周期独立

银行股中度跟随

平安 0.41 ·
招商 0.31

两家都中度同步大盘 · 符合直觉

样本外 R^2 大幅负数

$A=-0.18$ /
 $B=-0.19$

in=0.52/0.53 · 落差 135% · β
漂移痛点

► 01 高 β 低 R^2 陷阱:贝塔单独看会骗人

紫金矿业 $\beta=0.986$ 接近 1,看起来像典型大盘股,但 R^2 只有 0.240,意思是大盘只能解释紫金涨跌的 24%。剩下 76% 是商品周期(铜价/金价/矿价)独立逻辑驱动。教科书直觉「 $\beta \approx 1$ 等于跟大盘紧贴」是错的。判断股票跟大盘的关系, β 告诉你平均斜率, R^2 才告诉你散点贴不贴线,两个数字必须配套看。

► 02 Adj R^2 实测确认诚实者地位

基线 $R^2=0.4105$ / Adj $R^2=0.4097$ 。加 1 个噪声后 $R^2=0.4108$ (微涨)/Adj $R^2=0.4091$ (降);加 5 个 $R^2=0.4210$ /Adj $R^2=0.4161$;加 20 个 $R^2=0.4277$ (继续涨)/Adj $R^2=0.4105$ (回到基线)。普通 R^2 一路涨证明加垃圾也能让模型「看起来更好」,Adj R^2 几乎不动证明它对没贡献的变量数有惩罚。多变量回归只报 R^2 不报 Adj R^2 = 默认有问题。

► 03 样本外负 R^2 揭露 β 漂移

模型 A 只用沪深300一个真因子,训练 $R^2=0.5200$,测试 $R^2=-0.1829$,落差 135%。模型 B 加 24 个垃圾因子,训练 $R^2=0.5293$,测试 $R^2=-0.1921$,落差 136%。两个模型样本外都是大幅负数(预测比直接用样本均值还差)。模型 B 加 24 噪声后样本外只比 A 差 0.0092,这反过来说明:糟糕的根源不是过拟合,是 β 漂移(训练期和测试期市场结构变了)。即便最简单的单因子线性模型也撑不住。

05 · REAL MARKETS · 真实市场案例

A 股 · 港股 · 美股 · 加密 全覆盖

// 每个案例都有具体标的和数字,方便你立刻验证

Cremers
与
Petajisto
2009
Active
Share 论
文

美国主动股票基金

查 1980-2003 年所有美国主动股票基金,发现 30%+ $R^2 > 0.95$ 收主动费拿被动业绩。论文一发 SEC 监管跟上,数千只 closet indexing 基金被迫调整或降费。Active Share 这个指标也成了行业标配。

中国
2020-2021
茅指数 /
宁组合现象

千亿级主动公募基金

多只'明星基金经理'掌舵的千亿主动基金互相抱团重仓茅台 / 五粮液 / 海天味业 / 宁德 / 隆基,对沪深300 R^2 在 0.85+,对茅指数 R^2 0.90+。本质上变成高费率茅指数 ETF。2022 年茅指数 -35%,基金净值同步腰斩,管理费照收 1.5%。

本节实测三
年日数据 ·
银行股 +
紫金 + 长
江

510300 沪深300 +
4 只 A 股

平安银行 $\beta=0.753$ / $R^2=0.411$ 中度跟随,招商银行 $\beta=0.673$ / $R^2=0.314$ 中度跟随 — 两家银行作为大盘权重板块共振,符合直觉。紫金矿业 $\beta=0.986$ 接近 1 但 $R^2=0.240$ — 高 β 低 R^2 反直觉发现,商品周期独立逻辑解释了 76% 涨跌。长江电力 $\beta=0.123$ / $R^2=0.022$ 防御股几乎独立。三层画像逼你修正『 β 高 = 跟大盘』的简化假设。

本节样本外
测试 · β
漂移实证

平安银行 vs 沪深
300 七比三训练测试

模型 A 只用大盘一个真因子,训练 $R^2=0.5200$,测试 $R^2=-0.1829$,落差 135%。这意味着过去两年训练的关系完全无法外推到最近三个月, β 在变。模型 B 加 24 个垃圾因子,训练 $R^2=0.5293$,测试 $R^2=-0.1921$ — 跟 A 几乎一样烂。糟糕的根源不是过拟合(否则 B 应该比 A 更糟),是结构变化。

AQR 多因子
模型 R^2 历
史

Asness 旗下因子基
金

Fama-French 三因子对个股 R^2 平均 0.7-0.8;扩展到五因子或加动量 R^2 可到 0.85。AQR 内部模型 R^2 0.75 区间是常态,比简单 CAPM 单因子(R^2 0.4-0.6)解释力强很多。但因子模型 R^2 高不等于 α 高, α 是残差里的均值, R^2 是解释力,两件事。

这些坑你不主动避 · 迟早会主动找上你

// 每个坑都附了避坑动作,而不是只描述现象

△ 01

把 R^2 当成 α 的度量

R^2 度量的是模型解释力,不是 α 。一只主动基金 R^2 高(0.95+)可能是抱指数躺平没 α ;一个择时策略 R^2 低(0.05)反而可能有 α (拉到的就是大盘解释不了的部分)。 R^2 和 α 在某种程度上是反向的 — α 越大,残差越大, R^2 越小。正确做法: R^2 看模型解释力, α 看回归截距 + 显著性,两者分开评估。

△ 02

只看 in-sample R^2 评估策略

in-sample R^2 用训练数据本身评估,几乎一定好看。实盘前必须做 out-of-sample 验证 — 用一段从未参与拟合的数据测模型解释力。经验: $R^2_{out} / R^2_{in} < 0.5$ 视为过拟合警告, < 0.3 直接砍模型。雪球大 V / 量化论文 / 私募市场介绍材料里 90% 都只报 in-sample R^2 ,要警惕。

△ 03

多变量回归不报 Adj R^2

普通 R^2 数学性质就是加变量必涨,加再多垃圾也不会降。如果一个研究材料只报 R^2 不报 Adj R^2 ,默认是有问题。实战:Fama-French 三因子论文都报 Adj R^2 ,严肃量化研究全部报双值,不报的多半是给散户看的'营销材料',不是真研究。

△ 04

不同样本期 R^2 直接比

牛市 / 震荡 / 熊市的 R^2 完全不同。比如 2014-2017 中国大牛市期间所有股票对沪深 300 R^2 普遍上升(板块统统跟着涨),2018-2019 震荡期 R^2 下降(各走各的)。如果你拿不同时段 R^2 直接对比策略,会得出错误结论。正确做法:固定样本期对比,或者用滚动窗口 R^2 看动态。

△ 05

R^2 低就放弃模型

金融数据噪声极大,即便最好的多因子模型 R^2 也只能做到 0.3-0.5(月度个股)。择时模型 R^2 0.05-0.10 已经是实战可用范围。判断模型好坏不能只看 R^2 高低,要看:① R^2 是否稳定 ② 截距(α)是否显著 ③ Sharpe 多少 ④ R^2_{out} 是否接近 R^2_{in} 。 R^2 低 + 其他三项达标 = 完全可以用的策略。

06 · STANDARD OPERATING PROCEDURE · 实战规则

R² 在策略评估的 SOP

// 按这套规则走,你的执行力会立刻拉到中等机构水平

- 01 评估任何模型必报 R^2 + Adj R^2 + R^2_{out} 三件套,缺一不可
- 02 R^2_{out} 除以 R^2_{in} 小于 0.5 视为过拟合警告 / 大于 0.7 视为稳健
- 03 主动基金对指数 R^2 大于 0.95 立即换 ETF — closet indexing 警钟
- 04 多变量回归必报 Adj R^2 ,只报普通 R^2 视为可疑材料
- 05 R^2 必须配 t 检验 / p 值 / Sharpe / alpha 一起看,单独看 R^2 无意义
- 06 不同样本期(牛市 / 震荡 / 熊市) R^2 不能直接比,必须固定区间或滚动窗口

► **纪律 > 灵感:** 量化做久的人都明白,赚钱的不是某一次绝妙判断,而是把规则坚持执行 1000 次。打印这一页,贴在你电脑边。

07 · RECAP · 一页课件总结

把这节课带走的几件事

// 打印或截图这一页, 3 天后再看一遍效果最好

- 01 R^2 是模型的解释力 — 棍子贴散点的紧密度, 在 0 到 1 之间, 越接近 1 解释力越强
- 02 公式 $R^2 = 1 - SS_{\text{res}} / SS_{\text{tot}}$, 等价于'拟合 y 与实际 y 相关系数的平方'
- 03 三种股票画像: 中 β + 中 R^2 (平安/招商两家银行 0.31-0.41, 跟随大盘); 高 β + 低 R^2 (紫金 $\beta=0.99$ / $R^2=0.24$, β 高但散点不贴线, 独立性强); 低 β + 低 R^2 (长江 $\beta=0.12$, 防御股)
- 04 高 β 低 R^2 陷阱: 贝塔接近 1 不等于跟大盘紧贴 — β 给斜率, R^2 给紧密度, 两个必须配套看
- 05 $\text{Adj } R^2$ = 多变量回归的诚实者, 加 20 个垃圾后基线 0.41 几乎不动, 普通 R^2 却一路涨到 0.43, 实战必报
- 06 样本内 R^2 vs 样本外 R^2 是策略评估金标准, 实测平安银行训练 0.52 测试 -0.18 落差 135%, 即便单因子模型也撑不住, 根本原因是 β 漂移
- 07 主动基金 $R^2 > 0.95$ = closet indexing 抱指数躺平, 投资者亏的是费用差
- 08 R^2 永远要和 贝塔 / t 值检验 / p 值 / Sharpe / alpha 配合, 不能单独决策

08 · SELF-CHECK · 自测题

答不上来的回看视频对应段落

// 这几道题都没标准答案,目的是逼你自己组织语言讲清楚

Q01 一只股票对沪深300 $R^2 = 0.85$, $\beta = 1.2$,你怎么解读这只股票的特征?它适合做主动选股池吗?

Q02 你的多因子模型加 5 个变量后 R^2 涨了 0.05 但 Adj R^2 反而降了 — 说明什么?该怎么处理?

Q03 某主动基金对沪深300 $R^2 = 0.97$, 收 1.5% 管理费。这个组合合理吗?如果不合理,应该买什么替代?

Q04 你的策略 in-sample $R^2 = 0.40$, out-of-sample $R^2 = 0.08$,落差 80%。这是什么诊断?如何改进?

Q05 $R^2 = 0.05$ 的多因子模型一定是坏模型吗?(提示:看择时模型在金融市场的典型 R^2 范围)

09 · NEXT STEP · 下一步

继续往前走

// 看完这节,下面是延伸方向 + 明天预告

推荐阅读 · FURTHER READING

// 听完今天的内容还想往深里挖的话

- ▶ Cremers & Petajisto 《How Active Is Your Fund Manager?》(Yale 2009)– Active Share + R^2 揭穿 closet indexing 的奠基论文
- ▶ Bodie / Kane / Marcus 《Investments》(12 版)– 投资学全球最常用教材, R^2 / Active Share / closet indexing 都有专章
- ▶ Cochrane 《Asset Pricing》(修订版,Princeton)– 资产定价权威教材, R^2 在因子模型里的角色推导极透彻
- ▶ Fama & French 《Common Risk Factors in the Returns on Stocks and Bonds》(1993)– 三因子模型对个股 R^2 的标杆数据
- ▶ Andrew Lo 《Adaptive Markets》(2017)– R^2 与适应性市场假说,以及为什么 R^2 会随市场状态变化
- ▶ Karl Pearson 《On the General Theory of Skew Correlation》(1905 系列)– R^2 的统计学起源
- ▶ statsmodels.OLS / sklearn.metrics.r2_score 文档 – Python 量化标配,看清两个库 R^2 计算的细微差异

NEXT LECTURE · 下一节预告

DAY 015 时间序列与平稳性

Day 15:时间序列与平稳性 — D14 我们用回归看横截面关系,但金融数据本质上是时间序列。一个根本问题:股价不平稳(均值随时间漂移),收益才平稳。下一节讲 ADF 检验、单位根、协整,以及为什么不平稳的数据做回归会得到'伪回归'的错误结论 — 这是配对交易的理论根基。