

QUANT FINANCE TERMINAL ·
v2.046

SYS://CURRICULUM/D037.MD · PHASE 2 ●
LIVE

LECTURE · 量化金融 365

DAY 037 / 365

P2 · PYTHON 量化工具栈

DEEP DIVE · 8 页深度版

多重索引与 groupby

// MultiIndex & GroupBy

KEY CONCEPTS · 三大要点

- ▶ MultiIndex
- ▶ groupby
- ▶ stack/unstack

01 · WHY THIS LESSON · 这节课为什么重要

本节定调

// 看完这一段你会知道:这节课跟你接下来 3 个月的学习节奏关系有多大

把一堆股票按行业分组、各算各的因子,是量化研究每天都在做的事。这一节用真实的多只跨行业 A 股,带你把 MultiIndex 多层索引、groupby 分组、stack/unstack 长宽互转、pivot_table 透视、行业中性化这五件套一次打通,顺便看穿"买了不同行业就等于分散"的错觉。

学习目标 · LEARNING OBJECTIVES

// 听课前默念一遍,听完之后回头打勾

- 01 理解 MultiIndex 多层索引为什么天生适合"多只股票 × 多个日期"的面板数据
- 02 掌握 groupby 的 split-apply-combine 3 步心法,会按行业分组算平均收益、波动等因子
- 03 会用 stack 把宽表叠成长表、unstack 把长表摊成宽表,在两种格式间自如切换
- 04 会用 pivot_table 一句话做出"行业 × 指标"的透视汇总
- 05 理解行业中性化:剔除行业整体涨跌后,衡量个股自己的真本事

02 · CONTEXT · 历史与背景

老周的"十只好票",其实在押三个赛道

// 不读历史的策略走不远

还记得第33课买十只票照样一起亏的老王吗。他的朋友老周看完很受教,这回特意精选了十只"基本面好"的票,自觉很分散。可一段行情走下来,赚的没赚到、亏的全亏上。他把十只票按行业分组一算才发现:十只里有五只挤在白酒和新能源两个赛道,正好占一半,所谓分散其实是把鸡蛋换了几个篮子接着押。更扎心的是,他重仓三只的新能源整个赛道两年是负的,而他只配了一只的公用事业(长江电力)反而最强,两年涨了五成。这一节我们就用 groupby,把这种"伪分散"用一张表算到明明白白,再用行业中性化告诉他:哪几只票是真有本事,哪几只只是躺在好赛道上被抬起来的。

03 · CORE CONCEPTS · 核心概念详解

把这几个概念彻底搞懂

// 听完视频后,确保你能给一个完全不懂的朋友讲清楚每一条

CONCEPT_01

MultiIndex 多层索引

就好比 Excel 里"大类 + 小类"两级表头。一只股票一条价格序列是一维的,而很多只股票 × 很多天,天然就是二维面板,用(日期, 股票)两层标签一标,取数、分组都顺手。

CONCEPT_02

groupby 与 split-apply-combine

简单讲就是分3步:先按某个标签把数据拆成几堆(split,比如按行业),每堆各算各的(apply,比如算平均收益),再把结果拼回一张表(combine)。班主任按小组统计平均分,就是这个套路。

03 · CORE CONCEPTS · 续 (2/3)

CONCEPT_03

stack 与 unstack

stack 把"每列一只股票"的宽表叠成一长条(长格式),unstack 反过来把长条摊开成宽表。长格式适合分组和存储,宽格式适合画图和看走势,两者随时互转。

CONCEPT_04

pivot_table 透视表

等于说就是 Excel 的数据透视表搬进代码:指定行是什么、列是什么、格子里放什么统计量(平均、求和、计数),一句话生成汇总表。

03 · CORE CONCEPTS · 续 (3/3)

CONCEPT_05

行业中性化

同一个赛道的票会一起涨跌,这部分涨跌不算个股的本事。用 groupby 把每只票减去所在行业的平均,剩下的才是它相对同行的超额,这一步叫行业中性化,是因子选股的基本功。

04 · PYTHON LAB · 真实可跑代码

groupby 五件套 — MultiIndex 面板 / split-apply-combine / stack-unstack / pivot_table / 行业中性化

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

► **实操原则:** 先跑通(哪怕硬编码),再优化(参数化/函数化),最后才追求精度(模型升级/特征工程)。散户量化最大的坑是没跑通就开始优化。

```
# day_037_groupby.py — 多重索引与groupby:MultiIndex / split-apply-combine / stack-  
unstack / pivot_table / 行业中性化  
# 用真实A股多只跨行业股票,按行业分组算因子,看穿"行业不同就分散"的错觉  
# 数据:baostock 日线(免费、稳定、国内零翻墙)  
import numpy as np  
import pandas as pd  
import matplotlib.pyplot as plt  
import baostock as bs  
  
pd.set_option('display.width', 160)  
pd.set_option('display.max_columns', 30)  
  
# 老周自以为分散的"十只好票"(其实挤在少数几个行业)+ 几只其他行业做对照  
STOCKS = {  
    'sh.600519': '茅台', 'sh.000858': '五粮液', # 白酒  
    'sz.300750': '宁德时代', 'sz.002594': '比亚迪', # 新能源  
    'sh.600036': '招商银行', 'sh.601318': '中国平安', # 金融  
    'sh.600276': '恒瑞医药', 'sz.000661': '长春高新', # 医药  
    'sh.600900': '长江电力', # 公用事业  
    'sh.601012': '隆基绿能', # 光伏(归新能源)  
}  
  
START, END = '2023-01-01', '2024-12-31'  
  
# 手工行业标签(教学用,真实可用baostock query_stock_industry)  
INDUSTRY = {
```

04 · PYTHON LAB · 真实可跑代码 · 续 (2/6)

groupby 五件套 — MultiIndex 面板 / split-apply-combine / stack- unstack / pivot_table / 行业中性化

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

```
'茅台': '白酒', '五粮液': '白酒',  
'宁德时代': '新能源', '比亚迪': '新能源', '隆基绿能': '新能源',  
'招商银行': '金融', '中国平安': '金融',  
'恒瑞医药': '医药', '长春高新': '医药',  
'长江电力': '公用事业',  
}  
  
print('==== 0. 数据拉取(baostock 多只跨行业日线)====')  
lg = bs.login()  
if lg.error_code != '0':  
    raise RuntimeError(f'baostock 登录失败:{lg.error_msg}')  
frames = {}  
for code, name in STOCKS.items():  
    rs = bs.query_history_k_data_plus(  
        code, 'date,close', start_date=START, end_date=END,  
        frequency='d', adjustflag='2')  
    rows = []  
    while (rs.error_code == '0') and rs.next():  
        rows.append(rs.get_row_data())  
    s = pd.DataFrame(rows, columns=['date', 'close'])  
    s['date'] = pd.to_datetime(s['date'])  
    s['close'] = s['close'].astype(float)  
    frames[name] = s.set_index('date')['close']  
bs.logout()  
  
# 铁律 39:dict 显式映射,绝不 df.columns= 赋值  
prices = pd.DataFrame({name: frames[name] for name in STOCKS.values()}).dropna()  
print(f'对齐后 {prices.index[0].date()} → {prices.index[-1].date()}, {len(prices)}  
个交易日, {prices.shape[1]} 只股票')  
rets = prices.pct_change().dropna() # 日收益宽表(行=日期,列=股票)
```


04 · PYTHON LAB · 真实可跑代码 · 续 (3/6)

groupby 五件套 — MultiIndex 面板 / split-apply-combine / stack-unstack / pivot_table / 行业中性化

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

```
# ===== 1. MultiIndex:把宽表叠成面板(长格式)=====
print('\n==== 1. MultiIndex 面板数据 ====')
# stack:把"每列一只股票"的宽表,叠成 (日期, 股票) 双层索引的一列长表
long = rets.stack()
long.index.names = ['日期', '股票']
print(f'宽表形状 {rets.shape} (行=日期 列=股票) → stack 长表 {long.shape} (双层索引一列)')
print('长表前 5 行:')
print(long.head())

# ===== 2. groupby:split-apply-combine 按行业分组 =====
print('\n==== 2. groupby 按行业分组算因子 ====')
ind_map = pd.Series(INDUSTRY, name='行业')
# 给长表贴行业标签
df_long = long.rename('日收益').reset_index()
df_long['行业'] = df_long['股票'].map(INDUSTRY)
# 每只股票两年累计收益
cum_by_stock = (1 + rets).prod() - 1
ind_of_stock = pd.Series(INDUSTRY)
ind_cum = cum_by_stock.groupby(ind_of_stock).mean().sort_values(ascending=False)
print('各行业平均累计收益(split-apply-combine):')
for ind, v in ind_cum.items():
    print(f' {ind:6s} {v*100:6.1f}%')
ind_count = ind_of_stock.value_counts()
print('老周持仓的行业分布(只数):')
for ind, c in ind_count.items():
    print(f' {ind:6s} {c} 只')
top2 = ind_count.head(2)
print(f'最集中的两个行业占了 {top2.sum()}/{len(STOCKS)} 只 = {top2.sum()}/len(STOCKS)*100:.0f}%,所谓分散其实在押赛道')

# ===== 3. unstack:长格式 → 宽格式(行业 × 日期 透视)=====
```

04 · PYTHON LAB · 真实可跑代码 · 续 (4/6)

groupby 五件套 — MultiIndex 面板 / split-apply-combine / stack-unstack / pivot_table / 行业中性化

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

```
print('\n==== 3. stack / unstack 长宽互转 ====')
daily_ind = df_long.groupby(['日期', '行业'])['日收益'].mean() # 每天每行业平均日收益 (长)
ind_wide = daily_ind.unstack('行业') # → 行=日期 列=行业(宽)
print(f'每天每行业平均收益:长表 {daily_ind.shape} --unstack--> 宽表 {ind_wide.shape} (行=日期 列=行业)')
ind_cum_curve = (1 + ind_wide).cumprod()
print('各行业期末净值(起点 1.0):')
for ind in ind_cum_curve.columns:
    print(f' {ind:6s} {ind_cum_curve[ind].iloc[-1]:.3f}')

# ===== 4. pivot_table:透视表 =====
print('\n==== 4. pivot_table 透视 ====')
df_long['年月'] = df_long['日期'].dt.to_period('M').astype(str)
pv = pd.pivot_table(df_long, values='日收益', index='行业', columns=None,
                    aggfunc=['mean', 'std', 'count'])
pv.columns = ['日均收益', '日波动', '样本数']
pv = pv.sort_values('日均收益', ascending=False)
print('按行业透视(日均收益 / 日波动 / 样本数):')
print((pv.assign(日均收益=lambda x: (x['日均收益']*100).round(3),
                 日波动=lambda x: (x['日波动']*100).round(2))))

# ===== 5. 行业中性化:groupby demean =====
print('\n==== 5. 行业中性化(groupby transform demean)====')
# 个股累计收益 减去 所在行业平均 = 剔除行业 beta 后的"个股真本事"
stock_ind = ind_of_stock
ind_mean_map = cum_by_stock.groupby(stock_ind).transform('mean')
neutral = cum_by_stock - ind_mean_map # 行业中性化后的超额
neutral = neutral.sort_values(ascending=False)
print('行业中性化后(剔除行业平均,看个股真本事)排名:')
for name, v in neutral.items():
```

```
print(f' {name:6s} 中性化超额 {v*100:6.1f}% (原始 {cum_by_stock[name]*100:6.1f}%, 行业均 {ind_mean_map[name]*100:6.1f}%)')
```

04 · PYTHON LAB · 真实可跑代码 · 续 (5/6)

groupby 五件套 — MultiIndex 面板 / split-apply-combine / stack-unstack / pivot_table / 行业中性化

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。

```
# ===== 画图 =====
plt.rcParams['axes.unicode_minus'] = False
# 图1:各行业平均累计收益柱状
fig, ax = plt.subplots(figsize=(10, 5))
ind_cum.plot(kind='barh', ax=ax, color='#d08770')
ax.set_title('各行业平均累计收益(2023-2024)')
ax.set_xlabel('累计收益')
for i, v in enumerate(ind_cum.values):
    ax.text(v, i, f' {v*100:.0f}% ', va='center')
plt.tight_layout(); plt.savefig('chart_01.png', dpi=110); plt.close()

# 图2:各行业净值曲线
fig, ax = plt.subplots(figsize=(11, 5.5))
for ind in ind_cum_curve.columns:
    ax.plot(ind_cum_curve.index, ind_cum_curve[ind], label=ind, linewidth=1.6)
    ax.axhline(1.0, color='gray', ls='--', lw=0.8)
ax.set_title('各行业平均净值曲线(起点 1.0)')
ax.legend(loc='best', ncol=2)
plt.tight_layout(); plt.savefig('chart_02.png', dpi=110); plt.close()

# 图3:持仓行业分布饼图
fig, ax = plt.subplots(figsize=(7, 7))
ax.pie(ind_count.values, labels=[f'{i}\n{c}只' for i, c in ind_count.items()],
    autopct='%1.0f%%', startangle=90)
ax.set_title('老周"十只好票"的行业分布 — 其实在押赛道')
plt.tight_layout(); plt.savefig('chart_03.png', dpi=110); plt.close()

# 图4:行业中性化前后对比
fig, ax = plt.subplots(figsize=(11, 5.5))
order = neutral.index
```

04 · PYTHON LAB · 真实可跑代码 · 续 (6/6)

groupby 五件套 — MultiIndex 面板 / split-apply-combine / stack- unstack / pivot_table / 行业中性化

// 复制到 Jupyter / VS Code 直接能跑。pip install 缺什么装什么。



```
x = np.arange(len(order))
ax.bar(x-0.2, [cum_by_stock[n]*100 for n in order], width=0.4, label='原始累计收
益', color='#81a1c1')
ax.bar(x+0.2, [neutral[n]*100 for n in order], width=0.4, label='行业中性化后',
color='#a3be8c')
ax.axhline(0, color='gray', lw=0.8)
ax.set_xticks(x); ax.set_xticklabels(order, rotation=35, ha='right')
ax.set_ylabel('%'); ax.set_title('行业中性化:剔除行业 beta 后的个股真本事')
ax.legend()
plt.tight_layout(); plt.savefig('chart_04.png', dpi=110); plt.close()

print('\n[done] 4 张图已保存,output.txt 见上方全部打印')
```


05 · CHART + ANALYSIS · 看图说话

回测结果


// · matplotlib 真实输出



老周"十只好票"的行业分布 — 其实在押赛道



行业中性化:剔除行业 beta 后的个股真本事



行业平均累计收益
(2023-2024)

公用事业
+50.6%(仅长江电力1只)、
金融
+20.4%、白酒
+2.3%、新能源
-8.2%(3只)、医药
-10.3%

老周持仓行业集中度

10只票分5个
行业:新能源
3、白酒2、金
融2、医药2、
公用1;最集中
的两个行业占
 $5/10 = 50\%$

各行业期末净值(起点1.0)

公用事业
1.506、金融
1.214、白酒
1.050、医药
0.865、新能
源 0.844

按行业透视 日均收益/日波动

公用
+0.090%/1.01%、金融
+0.052%/1.65%、白酒
+0.021%/1.87%、医药
-0.013%/2.14%、新能
源 -0.016%/2.33%

行业中性化(剔除行业均后的
个股超额)

宁德时代
+34.9%(原始
+26.7、行业
均-8.2)、恒
瑞 +30.7%、
比亚迪
+18.5%;长江
电力 0.0%(原
始+50.6但独
占公用,全靠赛
道)、隆基
-53.5%(最
差)

透视样本数

白酒/金融/医
药各2只→各
966个日收益
样本,新能源3
只→1449个,公
用1只→483个

► 01 **十只票五只挤两赛道:伪分散一分组就现形**

老周精选十只"好票"自觉分散,按行业 groupby 一算:新能源3只+白酒2只=5只挤在两个赛道,正好占一半(50%)。所谓分散其实是把鸡蛋换了几个篮子接着押同样的风。真正的分散看行业集中度,不是单纯的行业个数,这正是 groupby 一句话就能照出的妖。

► 02 **重仓的赛道最弱,只配一只的赛道最强**

扎心的反差:老周重仓3只的新能源整个赛道两年是负的(-8.2%),而他只配一只(长江电力)的公用事业反而最强,平均+50.6%、净值1.506。说明选对赛道比选个股更早一步决定胜负,而老周恰好押反了。

► 03 **行业中性化:扒掉赛道光环,看个股真本事**

长江电力原始+50.6%看着最牛,但行业中性化后超额=0——它就是它那个行业本身,全靠赛道抬。反过来宁德时代绝对收益+26.7%一般,剔除-8.2%的行业拖累后,中性化超额高达+34.9%,是十只里真本事最强的。这就是为什么因子选股必须先做行业中性化,否则排名全被强势赛道带偏。

► 04 **高收益往往伴随高波动:新能源最颠**

透视表显示新能源日波动2.33%最大、医药2.14%次之,而公用事业仅1.01%最稳。老周重仓的恰恰是波动最大、收益还为负的赛道。低波动的公用事业既稳又涨得最多,印证了"少亏就是多赚"。

► 05 **groupby 是 split-apply-combine 的肌肉记忆**

从"按行业算平均收益"到"按行业算波动、算中性化",全是同一个套路:split(按行业拆)→ apply(每组各算)→ combine(拼回表)。掌握这一个心法,横截面因子、分层回测、行业暴露监控全都通了,这是量化数据处理的日常基本功。

05 · REAL MARKETS · 真实市场案例

A 股 · 港股 · 美股 · 加密 全覆盖

// 每个案例都有具体标的和数字,方便你立刻验证

行业分组	基金经理评估持仓时,先按行业 groupby 看自己在哪些赛道超配、哪些低配,避免无意中押注单一行业
行业分组	量化选股算因子时,几乎都要先做行业中性化,否则因子排名会被强势行业整体带偏
行业分组	研究员用 pivot_table 把几百只票按"行业 × 月份"透视,一眼看出哪个赛道在哪个阶段最强
行业分组	ETF 和指数编制方按行业分组做权重上限约束,防止单一行业占比过高
行业分组	风控用 groupby 按行业汇总持仓暴露,监控行业集中度是否超标

这些坑你不主动避 · 迟早会主动找上你

// 每个坑都附了避坑动作,而不是只描述现象

△ 01

误以为行业不同就是分散

真正的分散看的是相关性和行业集中度。八只票分属四个行业,但五只挤在两个赛道,本质还是押注,groupby 一算就现形。

△ 02

groupby 后忘了选聚合方式

分完组必须告诉它每组怎么算(mean/sum/std)。直接打印分组对象只会得到一个看不懂的中态,记得跟上一个聚合函数。

△ 03

stack/unstack 弄混方向

stack 让表"变高变窄"(宽转长),unstack 让表"变矮变宽"(长转宽)。弄反了形状就不对,动手前先想清楚要哪种格式。

△ 04

行业中性化前没对齐行业标签

如果某只票的行业标签缺失或拼错,groupby 会把它单独分一组或归错组,中性化结果就失真。先确认每只票都有正确的行业标签。

△ 05

pivot_table 默认聚合是均值

不指定 aggfunc 时默认取平均,想要求和、计数得显式写明,否则汇总口径就错了。

多重索引与分组实战 7 条 SOP

// 按这套规则走,你的执行力会立刻拉到中等机构水平

- 01** 面板数据优先用 MultiIndex — 多只票多个日期,用(日期, 股票)双层索引,分组和对齐都干净。
- 02** groupby 3 步法记牢 — split 按什么分、apply 每组算什么、combine 怎么拼回,写之前先想清这3 步。
- 03** 分组必跟聚合 — groupby 后立刻接 mean/sum/agg,别让分组对象悬在半空。
- 04** 长格式存储、宽格式展示 — 存盘和分组用长格式,画图和看走势用 unstack 成宽格式。
- 05** 算因子先行业中性化 — 剔除行业整体涨跌,留下个股相对同行的超额,排名才公允。
- 06** 透视先想清行列和口径 — pivot_table 动手前定好 index、columns、aggfunc 三件事。
- 07** 分组前先核对分组键 — 确认行业标签等分组键无缺失、无错拼,否则分组结果不可信。

► **纪律 > 灵感:** 量化做久的人都明白,赚钱的不是某一次绝妙判断,而是把规则坚持执行 1000 次。打印这一页,贴在你电脑边。

把这节课带走的几件事

// 打印或截图这一页, 3 天后再看一遍效果最好

- 01 MultiIndex 多层索引天生适合"多只票 × 多个日期"的面板数据
- 02 groupby 是 split-apply-combine:按标签拆开、每堆各算、再拼回
- 03 stack 宽转长、unstack 长转宽,两种格式按需切换
- 04 pivot_table 一句话做出"行业 × 指标"的透视汇总
- 05 行业中性化剔除赛道整体涨跌,衡量个股自己的真本事
- 06 行业不同不等于分散,集中度和相关性才是分散的真标准
- 07 groupby 后必接聚合、中性化前先对齐行业标签

08 · SELF-CHECK · 自测题

答不上来的回看视频对应段落

// 这几道题都没标准答案,目的是逼你自己组织语言讲清楚

- Q01** groupby 的 split-apply-combine 三步分别指什么?(提示:split 按某个标签把数据拆成几组(如按行业),apply 对每组各自做计算(如算平均收益),combine 把每组结果拼回一张表。)
- Q02** stack 和 unstack 分别把表变成什么样?(提示:stack 把宽表(每列一只票)叠成长表,变高变窄;unstack 把长表摊成宽表,变矮变宽。长格式适合分组存储,宽格式适合画图。)
- Q03** 为什么算选股因子前要做行业中性化?(提示:同行业的票会一起涨跌,这部分不算个股本事。减去所在行业平均后,剩下的超额才反映个股相对同行的真实强弱,排名才不会被强势行业整体带偏。)
- Q04** 老周买了八只分属四个行业的票,为什么还说他没分散?(提示:因为八只里有五只挤在白酒和新能源两个赛道,行业集中度很高。分散看的是集中度和相关性,不是单纯的行业个数。)

09 · NEXT STEP · 下一步

继续往前走

// 看完这节,下面是延伸方向 + 明天预告

推荐阅读 · FURTHER READING

// 听完今天的内容还想往深里挖的话

- ▶ Wes McKinney 《Python for Data Analysis》(2022, O'Reilly)– pandas 作者亲笔,groupby 与 pivot_table 章节是最权威的入门
- ▶ pandas 官方文档《Group by: split-apply-combine》(2024)– 把分组3步讲得最清楚,例子可直接照搬
- ▶ pandas 官方文档《Reshaping and pivot tables》(2024)– stack/unstack/pivot_table 的标准参考
- ▶ Grinold & Kahn 《Active Portfolio Management》(1999, McGraw-Hill)– 行业中性化与因子构建的经典理论源头
- ▶ BARRA 《风险模型手册》(2008)– 行业因子与中性化在真实风控里怎么用,工业界标准做法

NEXT LECTURE · 下一节预告

DAY 038 缺失值处理

第38课讲缺失值处理:NaN 到底是什么、怎么用 ffill 和 interpolate 填补行情缺口,以及一个能让回测虚假平稳的致命大坑——停牌期千万不能简单前向填充。